2 | 압축의 효율성 분석

01 압축률과 데이터 손실

압축률이란 데이터 압축을 통해 압축 이후 파일의 용량이 얼마나 줄어들었는지의 정도를 말한다.

$$\text{압축률} = \frac{\text{원본 데이터 크기} - \text{압축된 데이터 크기}}{\text{원본 데이터 크기}}$$

손실 압축의 경우, 압축률이 높을수록 원본 데이터 손실이 커지고 복원이 어려울 수 있다. 압축률은 압축 방법에 따라 달라진다. 일반적으로 이미지나 소리 데이터 등의 대용량 파일은 손실 압축 방법을 많이 적용하여 압축률이 높다. 문자 데이터의 경우 압축 시 데이터가 손실되어 문자를 이해하는 데 어려움이 있기 때문에 일반적으로 무손실 압축 방법을 적용해 압축률이 낮은 편이다.

예제 **반복 길이 압축 방법으로 다음 데이터를 압축하여 압축률을 구해 보고 이 압축 기술이 항상 효율적인지 생각해 보자.**

원본 자료: ABBBCCCCC	원본 자료: AABCCDFGH
압축 자료: A1B3C5	압축 자료: A2B1C2D1F1G1H1

풀이

$$\text{압축률} = \frac{9-6}{9} = 0.33 \qquad \text{압축률} = \frac{9-14}{9} = -0.55$$

첫 번째 예는 압축으로 파일의 용량이 줄어들었다. 반면, 두 번째 예는 압축된 데이터의 크기가 더 커서 압축률이 음수이다. 이를 통해 반복 길이 압축이 항상 효율적이지는 않음을 알 수 있다.

문자의 바이트 수는 어떤 인코딩 방식을 사용하는지에 따라 달라진다. 문자열의 압축은 모든 문자와 숫자를 1바이트로 취급하는 것이 일반적이다.

해 보기 2 반복 길이 압축 방법으로 압축하기

흰색 픽셀은 W, 검정색 픽셀은 B, 노란색 픽셀은 Y로 표현할 때, 예시를 참고하여 칠한 색의 종류와 반복된 개수로 1, 2, 3, 6, 7행을 표현하고 압축률을 구해 보자.

예시

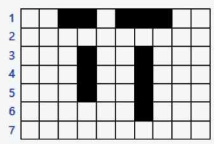

- 1행은 흰색 2칸, 검정색 2칸, 흰색 1칸, 검정색 3칸, 흰색 2칸으로 'WWBBWBBBWW'로 표현할 수 있다. 이를 칠한 색의 종류와 반복된 개수로 표현하면, 'W2B2W1B3W2'이다.
- 2행은 흰색 10칸으로 'WWWWWWWWWW'로 표현할 수 있다. 이를 칠한 색의 종류와 반복된 개수로 표현하면, 'W10'이다.

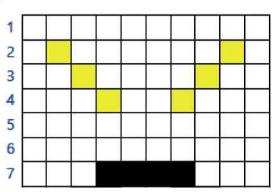

- 1행
- 2행
- 3행
- 6행
- 7행

Tip. 압축 전후의 데이터 크기는 문자의 개수를 기준으로 비교한다.

해 보기 3 이미지 데이터 압축해 보기

1 이미지 데이터 용량을 줄일 수 있는 사이트를 검색하여 접속한 후, 이미지 데이터의 용량을 자유롭게 줄여 보자.

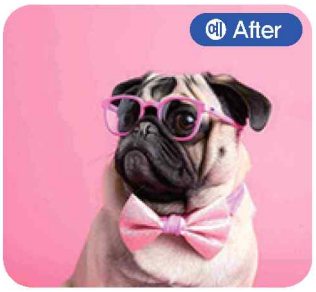

- 원본 파일 용량: (예) 91KB
- 압축 파일 용량: (예) 30KB

- 압축률을 구해 보자.

2 데이터 파일을 압축 및 변환할 때 고려할 요소를 생각해 보자.

- 데이터 파일의 종류:
- 필요한 저장 공간:
- 품질:
- 파일 형식:

Tip 이미지, 동영상 등 대용량 데이터 파일일수록 손실 방식을 많이 사용하고, 무손실 방식보다 손실 방식의 압축률이 우수하여 필요한 저장 공간이 작아진다. 또한 손실 방식의 경우 품질이 일부 저하되기도 하며, GIF보다 PNG 색상 표현이 우수하다.

알고 가기 압축을 통한 디지털 탄소 다이어트, 탄소 중립 실천하기

컴퓨팅 자원을 절약하고 탄소 중립을 실천하는 방법 중 하나로 데이터 압축이 있다. 압축을 통해 저장 공간을 절약할 뿐만 아니라, 데이터 전송 시 필요한 에너지를 줄일 수 있다. 대량의 데이터를 저장하고 처리하기 위해 필요한 에너지가 줄어들면, 이에 따른 전력 소비와 탄소 배출도 감소한다. 또한, 데이터 압축을 통해 네트워크로 데이터 전송 시 필요한 에너지도 줄일 수 있다. 이런 방식으로, 데이터 압축은 탄소 중립을 실천하는 데 중요한 역할을 한다.

2040년까지 디지털 기기를 이용한 활동으로 발생하는 이산화 탄소인 디지털 탄소 발자국이 전체 탄소 발자국의 14% 이상을 차지할 것으로 예상된다. 디지털 탄소를 줄이기 위해 우리가 쉽게 참여할 수 있는 사례 중 하나로 '불필요한 메일함 비우기'가 있다. 스팸*, 광고 등 불필요한 메일을 삭제해 정보 저장 과정에서 생기는 온실가스를 줄이기 위한 활동이다. 또한, 컴퓨터나 스마트폰을 사용할 때 절전 모드나 밝기 조절로 화면 밝기를 낮게 설정해도 이산화 탄소를 줄일 수 있다.

*스팸: 이메일을 통해 대량으로 전송되는 원치 않는 메시지를 말한다.

소단원 1분 요약

1. 압축은 원본 데이터를 더 작은 용량의 데이터로 표현하는 것이다. 일반적으로 문자, 이미지, 소리, 동영상 등 여러 디지털 데이터에 적용된다.
2. 데이터 압축을 통해 한정된 저장 공간에 많은 정보를 저장할 수 있고, 전송의 효율성을 높일 수 있다.
3. 디지털 데이터에 압축 기법을 적용하여 원본 데이터와 품질 및 용량 등을 평가할 수 있다.

소단원 자기 평가

평가 항목	평가 기준		
	잘함	보통	노력
1. [지식·이해] 디지털 데이터 압축의 개념과 필요성을 설명할 수 있다.			
2. [과정·기능] 디지털 데이터 압축의 효율성을 분석하고 평가할 수 있다.			

정보 탐구 활동

반복 길이 압축을 통해 압축의 효율성 분석하기

반복 길이 압축 방법을 통해 입력받은 값의 압축 효율성을 분석해 보자. 이를 위해 **str1** 변수에 압축할 데이터를 대입하여, 압축 전과 후의 크기를 바탕으로 압축률을 구해 보자.

※ Colab에 접속하여 다음 코드를 작성해 보자.

228쪽 〈부록 1〉 구글 코랩 활용하기 참조

프로그램

```
# str1에 압축할 데이터
# str2에 압축된 데이터
str1 = input('압축할 데이터를 입력하세요.')
str2 = ''
# 반복문의 범위 설정(압축할 데이터의 길이에 따라)
count = 1
for i in range(len(str1)-1):
  if str1[i] == str1[i+1]:
    count = count + 1
  else:
    str2 = str2 + str1[i] + str(count)
    count = 1
str2 = str2 + str1[i+1] + str(count)
print('압축할 데이터 :', str1)
print('압축된 데이터 :', str2)
print((len(str1) - len(str2)) / len(str1))
```

코드에서는 변수 str1을 생성하여 압축할 데이터를 대입하고, 변수 str2에 압축된 데이터를 담는다. 압축할 데이터의 길이만큼 반복해서 확인하기 위해 for 반복문의 범위를 설정하고, 연속적으로 반복되는 문자가 있을 때 그 반복되는 횟수만큼 count를 증가한다. 연속적으로 문자가 반복되지 않을 때는 else 구문이 실행된다.

1 압축할 데이터의 글자 수

2 압축된 데이터의 글자 수

3 압축률 = (원본 데이터 크기 - 압축된 데이터 크기) / 원본 데이터 크기

탐구 활동 자기 평가	평가 항목	평가 기준		
		잘함	보통	노력
	1. 압축의 효율성을 분석하여 평가할 수 있는가?			

• 잘함 (내용을 이해하고 설명함) • 보통 (내용을 이해함) • 노력 (내용을 부분적으로 이해함)