04 데이터 시각화

✚ 학습 목표 •데이터 시각화의 의의와 방법을 설명할 수 있다.
•빅데이터 분석 도구를 활용하여 시각화한 데이터의 의미와 가치를 해석할 수 있다.

✚ 학습 요소 •데이터 시각화, 데이터 해석

생각 깨우기 역사 속 데이터 시각화 사례를 살펴보자.

18세기 유럽에서 콜레라는 많은 사람에게 참혹한 피해를 줬다. 당시 영향력 있던 뉴욕 트리뷴 신문은 1849년 여름 콜레라 전염병으로 인한 사망자 수를 선 그래프로 시각화해 제시함으로써 피해의 심각성을 효과적으로 전달했다.

콜레라의 감염 원인이 밝혀지지 않았던 1854년, 의사 존 스노(John Snow)는 콜레라 환자의 집 위치를 지도에 표시하는 시각화하는 작업을 통해, 당시 식수로 활용되는 펌프가 있는 브로드 거리를 중심으로 콜레라 환자의 집이 밀집되어 있음을 알 수 있었다. 사망자의 위치와 밀집도를 지도 위에 나타냄으로써 콜레라의 감염 원인이 물이라는 것을 알게 된 것이다.

뉴욕 트리뷴의 콜레라 선 그래프

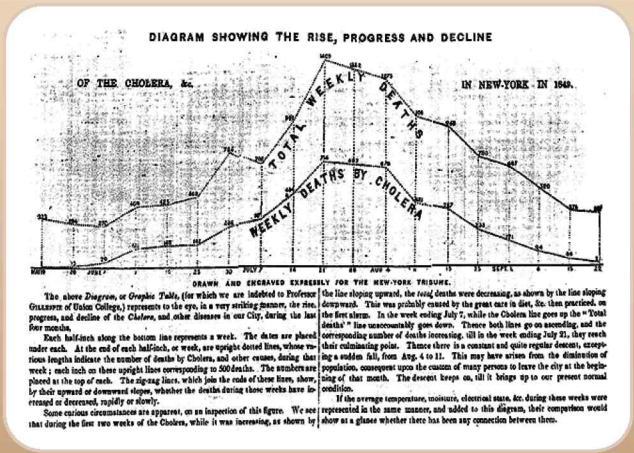

존 스노의 콜레라 지도

Q 데이터를 효과적으로 해석하는 방법에는 무엇이 있을까?

1 | 데이터 시각화의 이해

01 데이터 시각화의 의의

데이터 시각화는 수치나 통계 데이터를 도표, 그래프, 지도 등 시각적 형태로 표현하는 것을 말한다. 데이터 전체가 단순히 나열되어 있다면 데이터의 의미를 한눈에 파악하기 쉽지 않다. 반면 데이터를 시각화하면 데이터가 나타내는 의미를 보다 쉽고 명료하게 파악할 수 있다. 또한, 데이터의 분포, 트렌드, 이상치 등 데이터의 성격을 쉽게 전달할 수 있고, 데이터 간의 관계와 추세 등을 확인할 수 있어 데이터 기반의 효과적인 의사 결정을 돕는다.

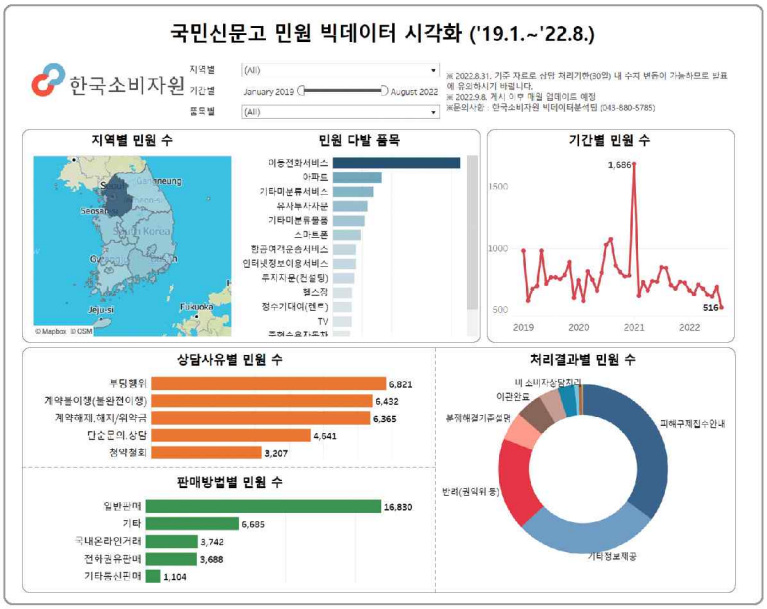

▲ 시각화된 데이터의 예

02 데이터 시각화 방법

시각화 방법에는 선 그래프, 막대 그래프, 원 그래프, 히스토그램, 산점도 등이 있으며, 도형, 방향, 길이, 너비, 색상, 위치 등의 요소를 활용해 효과적으로 표현할 수 있다.

알고 가기 인포그래픽(Infographic)

인포그래픽은 정보(Information)와 그래픽(Graphic)의 합성어로 복잡한 데이터를 시각화하여 쉽게 이해할 수 있는 형태로 표현한 그래픽 디자인이다. 넓은 의미에서 정보를 시각적인 형태로 전달하는 것으로, 정보를 빠르고 명확하게 전달하는 안내문, 홍보 매체, 뉴스 등에서 다양하게 활용되고 있다.

❶ 선 그래프

선 그래프는 점으로 값을 나타내고 그 점을 선으로 연결해 시각화한 그래프로, 연속적인 데이터의 흐름을 확인할 때 자주 사용된다. 일반적으로 가로축은 시간을, 세로축은 변화하는 수치를 나타냈을 때 시간에 따른 값의 변화를 파악하기에 매우 유용하다.

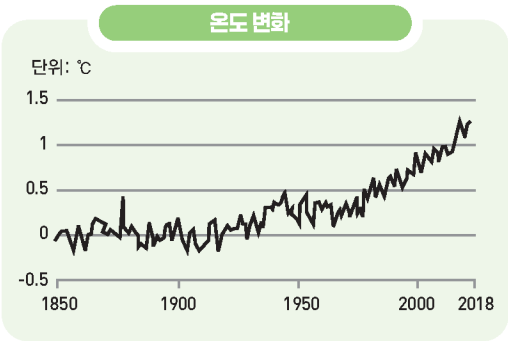

▲ **선 그래프** 연속적인 데이터의 흐름을 확인할 때 사용한다.

❷ 막대 그래프

막대 그래프는 값의 크기를 막대 모양의 길이를 통해 시각화한 그래프다. 막대 모양의 길이를 통해 어떤 값이 가장 크고 작은지 상대적인 크기를 쉽게 파악할 수 있다. 여러 항목의 값을 상대적으로 비교할 때 효과적이다.

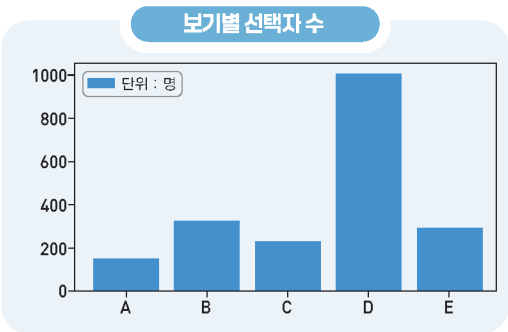

▲ **막대 그래프** 데이터 간의 상대적인 크기를 쉽게 비교할 수 있다.

❸ 원 그래프

원 그래프는 전체에서 각 항목의 비율을 원 영역의 크기를 통해 시각화한 그래프다. 원에서 각 항목마다 차지하고 있는 영역의 크기는 어떤 값이 크고 작은지 나타낸다. 항목 간 값의 크기 비교와 전체에 대한 비율을 파악할 때 많이 쓰인다.

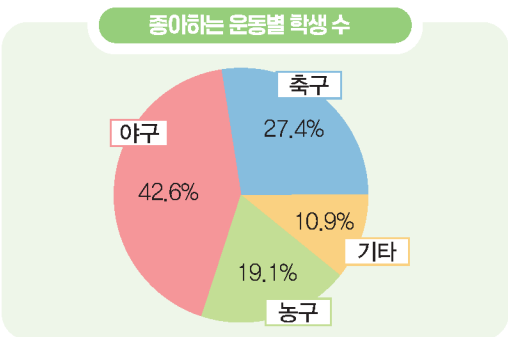

▲ **원 그래프** 원 영역 간 크기와 비율을 쉽게 파악할 수 있다.

❹ 히스토그램

히스토그램은 구간을 나누어 데이터의 전반적인 분포와 구간 내에 포함되는 빈도수를 시각화한 그래프다. 일반적으로 가로축은 값의 구간을, 세로축은 구간 내에 포함된 데이터의 빈도수를 표현한다. 값의 분포를 파악할 때 효과적이다.

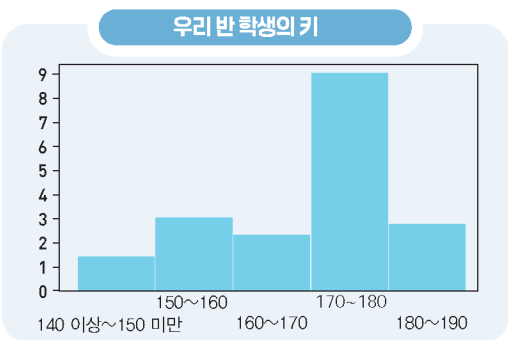

▲ **히스토그램** 데이터 값에 따른 빈도수 등을 파악할 때 효과적이다.

❺ 산점도

산점도는 속성값 사이의 관계를 시각화한 그래프다. 좌표 평면의 가로축과 세로축의 두 속성 값과 속성 간의 관계를 나타낼 때 자주 사용된다. 일반적으로 가로축은 독립 변수를, 세로축은 종속 변수를 나타낸다.

공부 시간과 시험 성적의 관계를 나타내는 산점도에서 각각의 점은 공부 시간과 시험 점수의 값을 나타낸다.

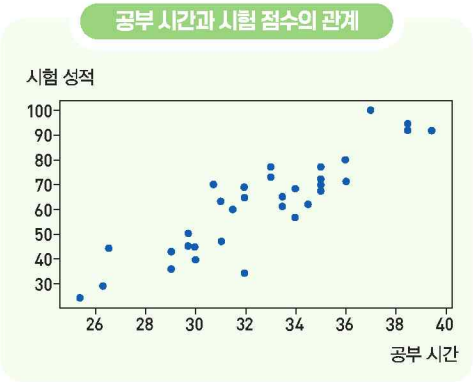

▲ 산점도 속성값 사이의 관계를 파악할 때 자주 쓰인다.

데이터의 종류

- 수치형 데이터: 숫자로 표현할 수 있는 데이터로 온도, 점수, 나이, 키, 몸무게 등이 있다.
- 범주형 데이터: 일정한 범주로 나눌 수 있는 데이터로 성별, 혈액형, 나이대 등이 있다.

Tip 산점도를 이용한 관계 분석

공부 시간 속성값이 변화할 때 시험 성적 속성값도 변화한다면, 공부 시간과 시험 성적 간에 상관관계가 있다고 본다. 반면 하나의 속성값이 변화할 때 다른 속성값이 변화하는 경향이 없다면, 두 속성 간에 상관관계가 없다고 본다.

두 속성 간의 관련 정도는 상관계수(r)로 나타내는데, 상관계수가 양수(+)인지 음수(-)인지에 따라 그래프의 방향성이 나타난다. 상관계수 범위는 '-1 < = r < = 1' 사이의 값을 가지는데 속성 간의 관련성이 클수록 절댓값 1에 가깝고, 관련성이 적으면 0에 가깝다.

해 보기 1 데이터 시각화의 의미와 가치 알아보기

데이터 시각화 사례를 조사하고, 그 의미와 가치를 해석해 보자.

예 시각화 사례

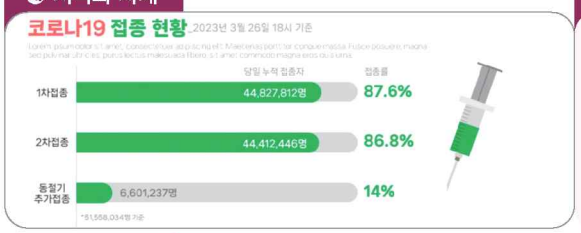

예 시각화 효과

예 2023년 3월 26일 18시 기준, 코로나19 1차 접종률은 87.6%, 2차 접종률은 86.8%이다. 가로 막대 그래프를 통해 1차 접종, 2차 접종, 동절기 추가 접종 현황을 쉽게 비교할 수 있다. 100% 비율에 해당하는 막대를 추가하여 90%에 이르는 접종률을 효과적으로 표현함으로써, 많은 국민들이 접종했음을 쉽게 알 수 있다.

시각화 사례

시각화 효과